

Sistemas Nebulosos para Avaliação de Corretude em Métodos Text-to-SQL

Eduarda Amaral de Oliveira

2022087857
eduardaoliveira@ufmg.br

Lucas Ribeiro da Silva

2022055564
lucasrsilvak@ufmg.br

Resumo—A avaliação de métodos Text-to-SQL tem avançado com o uso de Grandes Modelos de Linguagem (LLMs), mas métricas tradicionais como a acurácia de execução (Execution Accuracy - EX) falham por serem estritamente binárias, não capturando as ambiguidades e incertezas da linguagem natural. Este trabalho propõe um Sistema de Inferência Neuro-Nebuloso Adaptativo (ANFIS) para agregar métricas sintáticas e de execução de forma coesa e explicável, aproximando a classificação do julgamento humano e avaliando as métricas. O modelo foi treinado em PyTorch utilizando o benchmarking JABUTI-SQL. Os resultados demonstram que a abordagem proposta atinge alto grau de concordância com avaliadores humanos. Notavelmente, no cenário crítico onde a métrica tradicional zera ($EX = 0$) mas a consulta ainda é semanticamente adequada, o sistema neuro-nebuloso superou a melhor métrica unitária em cerca de 23%, alcançando uma coerência de 91% com a avaliação humana de acordo com o Kappa de Cohen.

Index Terms—Text-to-SQL, Sistemas Neuro-Nebulosos (ANFIS), Grandes Modelos de Linguagem (LLMs), Métricas de Avaliação, Kappa de Cohen.

I. INTRODUÇÃO

A tarefa Text-to-SQL tem avançado significativamente com o uso de grandes modelos de linguagem (LLMs). No entanto, o desenvolvimento de mecanismos de tradução de texto em linguagem natural para consultas em SQL ainda encontram significativas dificuldades. Uma destas dificuldades é avaliar se o SQL gerado pelo modelo de linguagem atende a pergunta feita pelo usuário. Em geral, os benchmarkings mais famosos em Text-to-SQL, como o Spider e o BIRD [1], [2] utilizam a métrica de Execution Accuracy (EX) ou métricas binárias para avaliar a performance dos modelos de acordo com um *ground truth*, isto é, uma resposta pré-definida para as perguntas de acordo com a resposta oferecida pelo modelador. Neste caso, caso a resposta oferecida pela LLM retorne os mesmos dados que a resposta pré-definida, a consulta é considerada correta e caso contrário, incorreta.

Em geral, a métrica EX é adequada para datasets simples como o BIRD e o Spider, mas falha ao refletir a complexidade dos datasets e dos usuários do mundo real por ser estritamente binária. Algumas das adversidades que podem surgir da complexidade do mundo real são:

- 1) **Pergunta ambígua ou incerta:** Uma pergunta em linguagem natural pode ser feita de maneira ambígua pelo usuário ou abrir margens para diversas respostas pelo modelo de linguagem, por exemplo, um usuário pode

perguntar sobre “a relação entre a compra e venda de medicamentos” e como a “relação” não é bem definida, a resposta da LLM pode ser bastante abrangente para a resposta da pergunta.

- 2) **Conversão lógica-texto:** Um usuário pode, ao elaborar sua pergunta definir um período de tempo, como por exemplo, “o número de medicamentos vendidos até 31/12/2024”, neste caso, o uso da palavra “até” deixa a opção de incluir o dia 31/12/2024 a ser definida de maneira arbitrária tanto pela LLM quanto pelo modelador do *ground truth*.
- 3) **Pequenas alucinações:** Os modelos de linguagens podem sofrer alucinações e gerar pequenos erros que não necessariamente comprometem a qualidade da resposta como um todo, mas que o EX inevitavelmente classificaria como errado, por exemplo, ao incluir uma coluna a mais, o uso de lógica de ordenamento não-explicitado diferente, entre outros.

Todos estes casos a resposta retornada pela LLM pode ser adequada para responder a pergunta do usuário e entretanto são rejeitadas pelas métricas tradicionais. Portanto, é necessário explorar alternativas as métricas tradicionais para considerar uma maior adequação do processo Text-to-SQL às incertezas da linguagem natural e do usuário.

II. REVISÃO DE LITERATURA

Para investigar o fenômeno e encontrar métricas alternativas para as tradicionais métricas binárias, foi realizada uma revisão de literatura com o objetivo de encontrar métricas que fossem mais suaves e refletissem melhor a incerteza inerente a pergunta em linguagem natural. Em geral, dividiu-se as métricas encontradas em dois tipos: métricas de execução, que avaliam se os dados retornados pela consulta são equivalentes aos dados esperados, e métricas de sintaxe, que observam se o SQL gerado se aproxima do SQL esperado.

Outras métricas apresentadas por Yu et al. [2] junto com o EX no Spider são as métricas sintáticas de **Exact Match** (EM) e **Component Match** (CM). A Exact Match observa se os componentes da consulta, i.e. (SELECT, WHERE, GROUP BY) possuem os mesmos elementos, independentemente da ordem textual, enquanto a Component Match decompõe a SQL em módulos e atribui scores individuais para a precisão

de Schema Linking (colunas/tabelas) e Operator Selection (JOINS, agregações).

Kanburoğlu, em sua revisão de literatura [3], cataloga entre a EX já discutida, uma outra métrica sintática conservativa, a **Logical-Form Accuracy** (LFA), que concentra em observar se o SQL gerado foi exatamente igual ao SQL esperado.

Sutanto et al. [4] propõe uma nova métrica de execução suave baseada em precisão e recall, a qual chama de **SOFT-F1 Score**. Esta métrica aborda a avaliação como um problema de Information Retrieval e calcula a média harmônica entre Precision (P) e Recall (R) sobre as tuplas retornadas do conjunto de dados. Por outro lado, Hazoom et al. [5] utiliza uma métrica de sintaxe baseada em precisão e recall, a qual chama de **Partial Component Match F1** (PCM-F1).

Katiker et al. [6] apresentam algumas outras métricas de execução. Entre as métricas apresentadas estão a **Valid Efficiency Score** (VES), que é uma métrica de custo computacional utilizada para verificar a viabilidade em custo computacional da consulta gerada em relação à esperada. A **Statistical Summarization** (StSu), que emprega dados estatísticos para validar a distribuição dos dados, por exemplo, comparando vetores de propriedades como μ, σ^2 , de colunas numéricas entre os dados gerados e esperados. Por fim, introduzem a **Similarity Scoring** (SiSc), que calcula a distância de Jaccard entre os conjuntos de dados retornados, quantificando a sobreposição informacional entre os espaços vetoriais dos resultados.

Raaij [7] propõe uma série de métricas sintáticas. Entre elas estão a **Levenshtein Correctness** (LeCo), que se baseia na distância de Levenshtein entre as strings, a **Structural Correctness** (StCo) que avalia se o grafo de junções e a hierarquia de cláusulas são equivalentes, sendo agnóstica a valores constantes e a **Skeleton Correctness** (SkCo) que abstrai a consulta para sua forma canônica lógica removendo todo o conteúdo específico do domínio.

Por fim, Pinna et al. [8] propõe a **Query Affinity Score** (QAS), com o objetivo de ser uma métrica híbrida. Para isso, divide a métrica em Similaridade Semântica, S_C , que transforma as palavras em vetores e calcula a similaridade de cosseno e a Similaridade de Tabela, S_T , que calcula a distância de edição mínima entre os dados.

Em resumo, as métricas estão na Tabela I.

III. METODOLOGIA

O objetivo deste trabalho é propôr uma maneira de aglomerar estas métricas de maneira coesa, semelhante a abordagem do QAS a fim de obter um resultado mais aproximado da classificação humana. Essa classificação humana foi realizada por três avaliadores diferentes e utilizada a classificação majoritária, por exemplo, se dois avaliadores consideram uma consulta “incorreta” e um considera “correta”, consideramos a consulta como “incorreta”. Para isso, faremos uso da inferência humana como o resultado ideal a ser atingido pelo sistema e consideraremos duas métricas principais a serem observadas.

- 1) **Acurácia:** A acurácia é uma das métricas mais simples para avaliar o desempenho de um modelo de classificação ou o nível de acerto entre avaliadores. Ela mede

Tabela I
RESUMO DAS MÉTRICAS DE AVALIAÇÃO TEXT-TO-SQL

Métrica	Tipo	Foco da Avaliação
EX	Execução	Identidade binária entre resultados.
EM	Sintática	Igualdade de componentes (SELECT, WHERE, etc).
CM	Sintática	Precisão de Schema Linking e Operadores.
LFA	Sintática	Identidade textual exata da consulta.
SOFT-F1	Execução	Precisão e Recall sobre as tuplas retornadas.
PCM-F1	Sintática	F1-score sobre sub-elementos da árvore SQL.
VES	Execução	Eficiência e custo computacional relativo.
StSu	Execução	Comparação de propriedades estatísticas (μ, σ^2).
SiSc	Execução	Distância de Jaccard entre conjuntos de dados.
LeCo	Sintática	Distância de Levenshtein entre strings SQL.
StCo	Sintática	Equivalência de grafos de junção e hierarquia.
SkCo	Sintática	Abstração da forma canônica lógica (esqueleto).
QAS	Híbrida	Similaridade semântica e de tabela (edit distance).

a proporção de predições ou classificações corretas em relação ao total de casos analisados.

- 2) **Kappa de Cohen:** O Kappa de Cohen (κ) é uma métrica estatística utilizada para medir o grau de concordância entre avaliadores ou métodos que classificam itens em categorias mutuamente exclusivas. Diferente da acurácia simples, o Kappa corrige o efeito do acaso, ou seja, desconta a concordância que ocorreria puramente por sorte ou vícios algorítmicos.

Com as métricas definidas, classificaremos como melhor a métrica que atingir o maior Kappa, e como método de treinamento utilizaremos um sistema de inferência nebuloso. Esta escolha se deve a explicabilidade do sistema de inferência nebuloso e a possibilidade de compreender como cada métrica afeta o sistema como um todo. Testaremos nosso sistema de inferência em quatro cenários diferentes, todos os quatro construídos a partir do benchmarking do banco de dados JABUTI-SQL (Joint Annotated Benchmark for User-centric Text-to-SQL In Real Health Data), um benchmark construído a partir de múltiplas bases públicas a partir do Portal de Dados Abertos do SUS, ou DATASUS. O benchmarking possui 191 consultas divididas em simples, médias e complexas.

Essa escolha se justifica pela grande complexidade dos dados no benchmark e pela grande margem de interpretação das consultas utilizadas na construção do mesmo.

- 1) **Todas as Consultas (C1):** Para esse cenário, considera-se todas as consultas do dataset.
- 2) **Sem ambiguidade (C2):** Para esse cenário, desconsidera-se as consultas com ambiguidades

muito fortes nas perguntas.

- 3) **Sem erros de sintaxe (C3):** Para esse cenário, desconsidera-se, além das consultas ambíguas, as consultas com erros de sintaxe. Note que as métricas de execução serão sempre 0 quando houver erro de sintaxe, mas as métricas sintáticas ainda podem pontuar.
- 4) **Consultas com EX = 0 (C4):** Para esse cenário, desconsidera erros de sintaxe e perguntas ambíguas e considera-se apenas os casos onde $EX = 0$. Este é o cenário mais importante e crítico para o sistema de inferência, porque é onde o classificador binário erra mas a consulta ainda pode ser respondida de maneira adequada de acordo com uma interpretação mais subjetiva.

Para otimizar o desempenho do classificador e mitigar a necessidade de ajuste manual das funções de pertinência, o modelo foi estendido para uma arquitetura ANFIS baseada em redes neuro-nebulosas adaptativas. Esta abordagem foi desenvolvida utilizando a biblioteca PyTorch, permitindo que os parâmetros do sistema fossem otimizados simultaneamente via retropropagação de erro (gradiente descendente). O modelo adota uma estrutura baseada no sistema de inferência de Takagi-Sugeno de primeira ordem, sendo dividido em camadas computacionais funcionais:

- 1) **Camada de Fuzificação (Antecedentes):** As métricas selecionadas são mapeadas para dois graus de pertinência nebulosos. Um exemplo pode ser visto na figura 1. Foram implementadas funções de pertinência Gaussianas customizadas como módulos do PyTorch (`nn.Module`), definidas por:

$$\mu_{A_i}(x) = \exp\left(-\frac{(x - c_i)^2}{2\sigma_i^2}\right) \quad (1)$$

onde os centros (c_i) e as variâncias (σ_i) são os parâmetros das premissas inicializados de forma regular no universo de discurso e otimizados durante o treinamento.

- 2) **Camada de Regras e Nós de Produto:** A força de disparo (*firing strength*) w_i de cada regra é determinada combinando os graus de pertinência dos antecedentes. Utilizou-se o operador lógico de conjunção (E) implementado por meio da norma-T do produto algébrico:

$$w_i = \mu_{A_{1,j}}(x_1) \times \mu_{A_{2,k}}(x_2) \times \dots \times \mu_{A_{N,m}}(x_N) \quad (2)$$

Onde o número total de regras geradas corresponde à combinação exponencial do número de funções de pertinência atribuídas a cada variável preditora.

- 3) **Camada de Normalização:** Os nós desta camada calculam a razão entre a força de disparo de uma regra específica e a soma total das forças de todas as regras ativas, normalizando a contribuição individual:

$$\bar{w}_i = \frac{w_i}{\sum_j w_j} \quad (3)$$

- 4) **Camada de Consequentes (Modelo Sugeno):** Ao contrário dos sistemas nebulosos tradicionais baseados em conjuntos linguísticos de saída, o consequente de cada

regra nesta arquitetura é computado como uma combinação linear linearmente parametrizada das variáveis de entrada:

$$f_i = \sum_i p_i \cdot m_i \quad (4)$$

onde p_i representam o conjunto de coeficientes lineares (parâmetros consequentes) a serem aprendidos pela rede e m_i as métricas.

- 5) **Camada de Saída (Defuzificação):** A resposta contínua final do sistema ($\hat{y}$) é gerada pela agregação do produto entre a força de disparo normalizada e o resultado do consequente linear de cada regra:

$$\hat{y} = \sum_i \bar{w}_i \cdot f_i \quad (5)$$




Figura 1. Função de Pertinência de SOFT-F1 com 2 Gaussianas.

Para a convergência do modelo, aplicou-se uma função de perda baseada no Erro Quadrático Médio (*Mean Squared Error - MSE*) calculada em relação às anotações humanas do dataset (*Maioria*). Além disso, o conjunto de consultas foi separado em treinamento e teste a partir da validação cruzada 70-30 para evitar *overfitting* e permitir uma generalização do modelo. Os parâmetros dos antecedentes (c_i, σ_i) e consequentes (p_i) foram ajustados de forma ponta a ponta (*end-to-end*) através do otimizador Adam, aplicando binarização via limiar de decisão na saída contínua para posterior extração das métricas de Acurácia e Kappa de Cohen. As métricas VES, StCo e LFA não foram utilizadas no treinamento do ANFIS.

IV. EXPERIMENTOS

Para os primeiros experimentos realizados, calculou-se a acurácia e o Kappa de Cohen para cada uma das métricas apresentadas anteriormente, exceto pela métrica VES, de maneira individual em cada um dos cenários descritos. Os resultados estão na Tabela II.

Em geral, observamos que o Kappa de Cohen encontrado para o Soft-F1 no cenário geral é um resultado considerado bom, com $\kappa = 0.88$, entretanto, ainda há muito espaço para melhora no cenário mais importante (C4), que é quando $EX = 0$ e o sistema não depende apenas de EX para inferir a correteza da consulta. Podemos observar que a métrica

Tabela II
RESULTADOS DE CONCORDÂNCIA

Métrica	Kappa de Cohen				Acurácia			
	C1	C2	C3	C4	C1	C2	C3	C4
Humano	1,00	1,00	1,00	1,00	0,41	0,40	0,69	0,44
<i>Métricas Baseadas em Execução</i>								
EX	0,74	0,79	0,78	0,00	0,25	0,26	0,46	0,00
Soft-F1	0,88	0,93	0,92	0,74	0,35	0,35	0,61	0,30
Stats	0,81	0,86	0,86	0,48	0,29	0,30	0,52	0,13
Similar	0,80	0,85	0,84	0,48	0,35	0,35	0,61	0,34
<i>Métricas Baseadas em Sintaxe</i>								
EM	0,32	0,31	0,30	0,06	0,13	0,10	0,18	0,09
CM	0,76	0,76	0,79	0,60	0,50	0,48	0,79	0,74
StCo	0,05	0,05	0,05	0,00	0,01	0,01	0,02	0,00
LFA	0,05	0,05	0,05	0,00	0,01	0,01	0,02	0,00
LeCo	0,76	0,77	0,82	0,63	0,49	0,49	0,64	0,56
SKCo	0,74	0,73	0,72	0,60	0,39	0,36	0,62	0,55
PCMF1	0,76	0,76	0,79	0,59	0,54	0,52	0,84	0,82
<i>Métricas Híbridas</i>								
QAS	0,85	0,88	0,88	0,61	0,37	0,37	0,64	0,45
ANFIS	0,92	0,97	0,97	0,91	0,37	0,37	0,64	0,45

de agregação fuzzy desenvolvida (ANFIS) tem uma melhora significativa nesse cenário, com um aumento de aproximadamente 23% em relação a melhor métrica unitária, o SOFT-F1, atingindo $\kappa = 0.91$, permitindo uma aproximação muito mais significativa da inferência humana.

Estudo das Métricas no ANFIS

Por mais que o resultado obtido pelo ANFIS seja mais próximo da inferência humana, é importante que o resultado do ANFIS seja explicável para que possamos entender quais métricas melhor contribuem para uma avaliação mais realista das consultas Text-to-SQL. Com esse objetivo, realizou-se alguns experimentos com os resultados do ANFIS e as métricas a fim de compreender melhor os resultados obtidos e confirmar que o modelo obteve combinações válidas. O primeiro experimento foi executar o Permutation Feature Importance (PFI) [9], que embaralha iterativamente os valores de cada variável, anulando associações espúrias e isolando o impacto preditivo real de cada métrica no sistema. Como o resultado depende do ANFIS atual, o ANFIS foi treinado 5 vezes e foi tirada a média. O resultado é mostrado na Fig. 2.

Podemos observar pelo gráfico que a maior discriminabilidade para o Kappa de Cohen se distribui com com a Statistical Summarization, Similarity Score e Soft-F1, além da tradicional EX. As demais métricas contribuem relativamente pouco para a inferência humanizada do ANFIS.

Além disso, foi possível obter quais regras são mais importantes para o modelo, com a Regra 0 (todos baixos) sendo a mais importante. Em geral, observa-se que regras que consideram $\text{Soft-F1}_{\text{Alto}} \wedge \text{Stats}_{\text{Alto}} \wedge \text{Similarity}_{\text{Alto}}$ possuem um maior impacto (frequência $\times$ magnitude) para o modelo. O impacto de cada regra pode ser visto na Fig 3.




Figura 2. Importância de Cada Métrica com PFI.




Figura 3. Impacto de cada regra no Modelo.

Para avaliar o comportamento do ANFIS, foi realizada uma outra comparação, com a ilustração do gráfico de superfície de decisão formado entre as métricas Soft-F1 e Execution Accuracy, da qual o resultado pode ser visto na Fig. 4.

Superfície de Decisão: Soft_F1 vs EX





Figura 4. EX vs. Soft-F1


Podemos observar que a parte verde do gráfico se concentra nas beiradas onde Soft-F1 possui os valores mais altos. Podemos observar que quando $EX = 1$, os valores em geral são mais altos que $EX = 0$, indicando certa influência, mas não o suficiente para afirmar que a consulta está errada, o que é especialmente observado quando Soft-F1 possui valores altos. Em geral, como são correlacionadas, dificilmente uma consulta terá $EX = 1$ com Soft-F1 próximo de 0, o que justifica valores baixos para $EX = 1$.

Outras análises foram feitas para a contribuição das métricas mais importantes no cenário C4 quando $EX = 0$, nomeadamente, Soft-F1, Similarity Score e Statistical Summarization. As superfícies destas métricas, duas a duas, são mostradas nas figuras abaixo:


Superfície: Soft_F1 vs Stats (Cenário $EX=0$)



Superfície: Soft_F1 vs Similarity (Cenário $EX=0$)



Superfície: Stats vs Similarity (Cenário $EX=0$)



Nesse caso, podemos observar como é necessário que pelo menos 2 das métricas estejam em seus valores altos para que a consulta seja considerada majoritariamente correta.

V. CONCLUSÕES

A partir da modelagem do sistema de inferência nebuloso, fomos capazes de agregar diferentes métricas, suaves e binárias e aproximar com sucesso a classificação da consulta SQL da avaliação humana realizada. Além disso, pela obtenção das regras de inferências utilizadas, podemos avaliar detalhadamente quais métricas são mais pertinentes para a avaliação de modelos Text-to-SQL isoladamente e quais combinações de métricas podem ser mais eficientes, além de analisar o comportamento das métricas combinadas. Por fim, ficam as limitações de ter testado em apenas em um dataset, o JABUTI-SQL, que se justifica pela escassez de datasets classificados manualmente por avaliadores.

REFERÊNCIAS

- [1] J. Li, B. Hui, G. Qu, J. Yang, B. Li, B. Li, B. Wang, B. Qin, R. Geng, N. Huo *et al.*, "Can llm already serve as a database interface? a big bench for large-scale database grounded text-to-sqls," *Advances in Neural Information Processing Systems*, vol. 36, pp. 42 330–42 357, 2023.
- [2] T. Yu, R. Zhang, K. Yang, M. Yasunaga, D. Wang, Z. Li, J. Ma, I. Li, Q. Yao, S. Roman *et al.*, "Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-sql task," in *Proceedings of the 2018 conference on empirical methods in natural language processing*, 2018, pp. 3911–3921.
- [3] A. B. Kanburoğlu and F. B. Tek, "Text-to-sql: A methodical review of challenges and models," *Turkish Journal of Electrical Engineering and Computer Sciences*, vol. 32, no. 3, pp. 403–419, 2024.
- [4] P. Sutanto, J. Kenrick, M. Lorenz, and J. Santoso, "Llm-driven data generation and a novel soft metric for evaluating text-to-sql in aviation mro," *arXiv preprint arXiv:2506.13785*, 2025.
- [5] M. Hazoom, V. Malik, and B. Bogin, "Text-to-sql in the wild: A naturally-occurring dataset based on stack exchange data," in *Proceedings of the 1st Workshop on Natural Language Processing for Programming (NLP4Prog 2021)*, 2021, pp. 77–87.

- [6] R. Katikeri, A. N. R. Pepakayala, L. Kuncham, R. Barla, K. Tarun, S. Charan, and A. Vaid, "Evolve: Evaluation of language-to-sql validity and effectiveness-a detailed review framework for complex text-to-sql queries," in *2024 IEEE International Conference on Big Data (BigData)*. IEEE, 2024, pp. 1999–2004.
- [7] R. v. Raaij, "Metrics and benchmarks for evaluating dutch prompt-based text-to-sql systems," Master's thesis, 2025.
- [8] G. Pinna, Y. Perezhohin, L. Manzoni, M. Castelli, and A. De Lorenzo, "Redefining text-to-sql metrics by incorporating semantic and structural similarity: G. pinna et al." *Scientific Reports*, vol. 15, no. 1, p. 22357, 2025.
- [9] A. Altmann, L. Toloşi, O. Sander, and T. Lengauer, "Permutation importance: a corrected feature importance measure," *Bioinformatics*, vol. 26, no. 10, pp. 1340–1347, 2010.